Caso de Estudio – ADY1100 Preprocesamiento de Datos

El **Banco Financiero Global**, una institución líder en servicios financieros, se enfrenta a un entorno competitivo que exige estrategias de marketing más efectivas. Uno de sus productos principales, los **depósitos a plazo**, ha mostrado una tasa de conversión inferior a las expectativas a pesar de las inversiones significativas en campañas publicitarias. Este rendimiento limitado afecta los objetivos estratégicos de la organización, particularmente en la captación de nuevos clientes y la fidelización de los actuales.

En respuesta, la alta gerencia ha decidido impulsar el uso de herramientas analíticas avanzadas. Esto incluye desarrollar un modelo predictivo capaz de identificar a los clientes con mayor probabilidad de contratar un depósito a plazo. Antes de construir dicho modelo, es imprescindible **preparar los datos** disponibles para asegurar su calidad y usabilidad. Tu rol, como integrante del equipo de Ciencia de Datos y Analítica, será garantizar que el conjunto de datos proporcionado sea apto para el análisis, sentando las bases para el éxito del proyecto.

Descripción del Escenario

El conjunto de datos utilizado, denominado "bank-additional-full.csv", recopila información de campañas de marketing realizadas entre mayo de 2008 y noviembre de 2010. Este dataset contiene datos de 41,188 clientes y 20 atributos, que abarcan detalles demográficos, financieros y de interacciones previas, además de la variable objetivo "y", que indica si el cliente contrató ("sí") o no ("no") un depósito a plazo. Sin embargo, el análisis directo enfrenta varios desafíos clave:

Datos faltantes: Atributos categóricos como el nivel educativo o el estado laboral presentan valores "desconocido", que reflejan información ausente.

Outliers: Variables numéricas como la duración de la llamada y el índice de precios al consumidor contienen valores extremos que pueden sesgar los resultados si no se manejan adecuadamente.

Variables irrelevantes: Algunos atributos, como la duración del último contacto, afectan directamente la variable objetivo, pero su inclusión podría llevar a conclusiones no realistas ni éticas.

Codificación de variables categóricas: Muchas variables, como el estado civil, están en formato textual, dificultando su uso en algoritmos de machine learning que requieren datos numéricos.

Escalamiento: Variables numéricas como la edad y el balance promedio tienen rangos muy diferentes, lo que podría afectar negativamente los algoritmos sensibles a las magnitudes.

El dataset posee los siguientes campos:

Archivo "Bank-additional-full.csv" Diponible en AVA

N	Nombre del atributo	Descripción	Tipo	Valores posibles
1	edad	Edad del cliente	Numérico	-
2	trabajo	Tipo de trabajo del cliente	Categórico	"administrador", "obrero", "empresario", "empleado doméstico", "gerente", "jubilado", "autónomo", "servicios", "estudiante", "técnico", "desempleado", "desconocido"
3	estado civil	Estado civil del cliente	Categórico	"divorciado", "casado", "soltero", "desconocido"
4	educación	Nivel educativo del cliente	Categórico	"básico.4a", "básico.6a", "básico.9a", "bachillerato", "analfabeto", "curso profesional", "título universitario", "desconocido"
5	mora	Si el cliente tiene crédito en mora	Categórico	"no", "sí", "desconocido"
6	vivienda	Si el cliente tiene un préstamo para vivienda	Categórico	"no", "sí", "desconocido"
7	préstamo	Si el cliente tiene un préstamo personal	Categórico	"no", "sí", "desconocido"
8	contacto	Tipo de comunicación del último contacto	Categórico	"celular", "teléfono"
9	mes	Mes del último contacto	Categórico	"ene", "feb", "mar", "abr", "may", "jun", "jul", "ago", "sep", "oct", "nov", "dic"
10	día_de_la_semana	Día de la semana del último contacto	Categórico	"mon", "tue", "wed", "thu", "fri"
11	duración	Duración del último contacto en segundos	Numérico	-
12	campaña	Número de contactos realizados durante esta campaña	Numérico	-

13	pdays	Días transcurridos desde el último contacto en una campaña anterior	Numérico	- (999 significa que no fue contactado previamente)
14	anterior	Número de contactos realizados antes de esta campaña	Numérico	-
15	poutcome	Resultado de la campaña de marketing anterior	Categórico	"fracaso", "inexistente", "éxito"
16	emp.var.rate	Tasa de variación del empleo (indicador trimestral)	Numérico	-
17	cons.price.idx	Índice de precios al consumidor (indicador mensual)	Numérico	-
18	cons.conf.idx	Índice de confianza del consumidor (indicador mensual)	Numérico	-
19	euribor3m	Tasa del euribor a 3 meses (indicador diario)	Numérico	-
20	nr.employed	Número de empleados (indicador trimestral)	Numérico	-
21	y	El cliente ha suscrito un depósito a plazo	Binario	"sí", "no"